

Análisis de Solicitud 01 - Nuevas Reatures: Reportes y Alertas SMS

Fecha: 2026-07-14 Restricción crítica: SIP-Edge en campo solo tiene acceso SMS (modem 4G Quectel EC25). No hay acceso Ethernet ni dashboard web disponible para los corresponsales. Toda entrega de información es vía SMS (texto plano, ~160 chars por mensaje, concatenables).

1. Aclaraciones sobre la solicitud

Los siguientes terminos los interpretamos de acuerdo al flujo establecido, sin embargo esperamos que pueda confirmar o aclarar si se trata del termino entendido o en caso contrario; explicar de forma un poco mas explicita a que refiere el termino utilizado.

Término del cliente	Realidad en SIP-Edge
Proveedor	Es la Hacienda . Ya existe como entidad (tabla <code>haciendas</code> , tool <code>get_breakdown_by_hacienda</code>).
Destino	Toda la caña va a la misma fábrica. No aplica filtro por destino.
Producto	Equivale a <code>tipo_cosecha</code> (Cosechadora / Cosecha manual). Ya existe como columna en <code>weighings</code> .
Vehículo	Ya existe como <code>tractomula</code> y <code>vagon</code> en <code>weighings</code> . No expuesto como filtro en tools actuales.

2. Features implementables (SMS)

Feature propuesta: `sms_analytics_v2` — Reportes SMS enriquecidos + Alertas automáticas

Depende de: F7 (`sms_service`), F8 (`ai_agent`), F27 (`sms_persistence`) — todas `done` .

2.1 — Filtros y agrupación nuevos

Qué piden	Cómo se implementa	Nueva tool / cambio
Rangos de fecha: Hoy, Ayer, Últimos 7 días, Mes actual, Personalizado	Shortcuts de fecha en tools. El LLM resuelve "hoy" → <code>date.today()</code> . Nueva tool <code>resolve_date_range</code> que traduce shortcuts a fechas YYYY-MM-DD.	Nueva tool + actualizar <code>TOOL_DEFINITIONS</code>

Qué piden	Cómo se implementa	Nueva tool / cambio
Agrupar por Día, Semana, Mes, Turno	Nuevo parámetro <code>agrupacion</code> en tools existentes. Turno ya existe en <code>get_shift_summary</code> .	Nuevo parámetro en <code>get_basic_stats</code> , <code>get_trend</code> , <code>get_material_composition</code>
Filtro por vehículo (tractomula/vagon)	Nuevo parámetro opcional <code>vehiculo</code> en tools de consulta.	Nuevo parámetro en tools existentes

2.2 — Métricas de operación nuevas

Métrica	Estado actual	Qué se necesita
Desviación estándar	✅ Ya existe en <code>get_basic_stats</code> (campo <code>std</code>)	Nada. Solo asegurar que el LLM la incluya en el resumen.
Tiempo promedio por pesaje	❌ No existe	Nueva tool <code>get_avg_weighing_time</code> : calcula delta entre <code>created_at</code> de pesajes consecutivos en un rango de fechas.
Tasa de rechazo/reproceso	❌ No existe	Nueva tool <code>get_anomaly_rate</code> : <code>COUNT(anomaly_log) / COUNT(weighings)</code> en rango de fechas.
Top 5 haciendas con más peso	❌ No existe como ranking	Nueva tool <code>get_top_haciendas</code> : <code>GROUP BY hacienda_id ORDER BY SUM(peso_total) DESC LIMIT N</code> .
Comparativo vs período anterior	❌ No existe	Nueva tool <code>get_period_comparison</code> : corre mismo query en período actual y período anterior, retorna Δ absoluto y $\Delta\%$.
OEE de báscula	❌ No existe infraestructura	No implementable (ver sección 3).

Total tools nuevas: 4 (`get_avg_weighing_time`, `get_anomaly_rate`, `get_top_haciendas`, `get_period_comparison`) **Tools modificadas:** 3 (agregar `agrupacion` y `vehiculo` como parámetros opcionales)

2.3 — Alertas estadísticas automáticas

Alerta	Cómo se implementa
Anomalía > X%: operador fuera del promedio	El engine de anomalías ya existe (<code>detect_anomalies</code> en <code>anomaly_detector.py</code>). Nueva condición: si <code>z_score > umbral_personalizable</code> , disparar SMS al admin.
Caída de producción: >20% menos pesajes vs promedio	Nuevo monitor en el loop del scheduler. Compara <code>COUNT(weighings)</code> de hoy (hasta ahora) vs promedio móvil de últimos 7 días. Si cae >20%, envía alerta SMS.
Outliers: fuera de 3 desviaciones estándar	Ya cubierto por <code>detect_anomalies</code> (Z-Score). Ajustar el umbral a 3σ .

Alerta	Cómo se implementa
Inactividad: 2h sin pesajes en horario laboral	Nuevo monitor de heartbeat. Si <code>MAX(weighings.created_at)</code> > 2h atrás y estamos en horario laboral (L-V 6am-10pm, S 6am-2pm), envía alerta SMS.

Infraestructura nueva necesaria:

- `AlertMonitor` : clase que corre en el scheduler de `sms_service` , evalúa 4 condiciones cada N minutos.
- Tabla `alert_log` (o columna `alert_type` en `sms_messages`): registro de alertas enviadas para evitar duplicados.
- Configuración en `config.yaml` :

```
alerts:
  anomaly_threshold_pct: 15.0
  production_drop_pct: 20.0
  inactivity_minutes: 120
  outlier_stddev: 3.0
  check_interval_minutes: 30
  active_hours_weekday: [6, 22]
  active_hours_saturday: [6, 14]
```

2.4 — Formato de entrega SMS

Qué piden	Viabilidad SMS
Resumen ejecutivo (3 bullets)	✅ Perfecto para SMS. El LLM ya genera resúmenes narrativos. Nueva instrucción de sistema: <i>"Responde SIEMPRE con 3 bullets: Total pesajes, anomalías detectadas, cambio vs período anterior."</i>
Gráfico PNG	❌ Imposible por SMS (ver sección 3)
Excel/CSV	❌ Imposible por SMS (ver sección 3)
PDF	❌ Imposible por SMS (ver sección 3)
Tabla formateada	❌ SMS no permite formato rico (ver sección 3)

2.5 — Configuración adicional

Qué piden	Implementación
Zona horaria GMT-5 Bogotá	✅ Agregar <code>timezone: "America/Bogota"</code> en <code>config.yaml</code> . Todos los schedulers usan <code>pytz</code> para convertir.
Días activos (L-V, L-S)	✅ Agregar <code>active_days: [1,2,3,4,5]</code> en <code>config.yaml</code> . El scheduler omite envíos en días inactivos.
Idioma/Formato números	✅ Ya en español. Agregar <code>number_format: es_CO</code> para separadores de miles (<code>.</code>) y decimales (<code>,</code>).
Plantillas pre-hechas	✅ Nueva tabla <code>report_templates</code> (ya existe en F17) o extender la existente con <code>template_type</code> : <code>gerencia</code> , <code>operaciones</code> , <code>calidad</code> . Cada plantilla define métricas

Qué piden	Implementación
	y umbrales propios.

2.6 — Flujos SMS programados

Horario	Reporte	Implementación
6:00 am — "Resumen Ayer"	Cantidad, promedio, top haciendas, anomalías	Nueva entrada en el scheduler de <code>sms_service</code> . Invoca <code>get_daily_summary(fecha=ayer)</code> + <code>get_breakdown_by_hacienda</code> + <code>detect_anomalies</code> . Formato: 3-bullet SMS.
Cada 4 horas — "Alerta Operación"	Solo si hay anomalías o caída	El <code>AlertMonitor</code> (sección 2.3) evalúa condiciones. Si alguna se dispara, envía SMS. Si no hay novedades, no envía nada (modo solo-excepción).
Lunes 7:00 am — "Resumen Semanal"	Tendencia, comparativo, desviación	Nueva entrada en el scheduler. Invoca <code>get_trend(semmana)</code> + <code>get_period_comparison(vs_semmana_anterior)</code> + <code>get_basic_stats</code> .

3. Items NO implementables

Solicitud del cliente	Motivo técnico
Gráficos PNG (tendencia, barras, torta)	SMS es transporte de texto. No soporta imágenes, binarios ni MMS. No hay acceso ethernet para servir las imágenes por otro canal.
Adjuntar Excel/CSV	SMS no transporta archivos. No hay canal alternativo (sin ethernet, sin email).
Adjuntar PDF	Misma restricción: SMS no transporta binarios.
Tablas formateadas	SMS es texto plano. Se puede usar formato ASCII rudimentario (guiones y pipes), pero no tablas ricas con alineación, colores ni celdas.
Dashboard web	Los corresponsales no tienen acceso ethernet ni navegador en campo. El dashboard admin existe (<code>/admin/reportes</code>) pero solo es accesible al admin <i>in situ</i> .
Filtro por Destino	Toda la caña va a la misma fábrica. Agregar este filtro no aporta valor porque siempre devolvería el mismo resultado.
Filtro por Proveedor	Ya está cubierto por el filtro de Hacienda (tabla <code>haciendas</code> , tool <code>get_breakdown_by_hacienda</code>). El cliente usó "proveedor" como sinónimo de hacienda.
OEE de báscula	OEE = Disponibilidad × Rendimiento × Calidad. Requiere: (a) tracking de uptime/downtime de la báscula, (b) velocidad nominal de pesaje, (c) tasa de defectos. Ninguna de estas métricas existe en SIP-Edge hoy. Implementar OEE real requeriría sensores de disponibilidad + contador de

Solicitud del cliente	Motivo técnico
	tiempo operativo. Se puede aproximar con <code>tiempo_promedio_pesaje</code> y <code>tasa_rechazo</code> como proxies simplificados.

4. Advertencia técnica — Impacto en el LLM local

Cada herramienta de análisis estadístico que se agregue se registra en `TOOL_DEFINITIONS` como una definición de función OpenAI-style. El inventario actual (12 tools) ya consume aproximadamente **3,200 tokens** solo en definiciones. Con las 4 tools nuevas propuestas más las 3 modificadas, el bloque de herramientas crecerá a **~4,500 tokens**.

Esto tiene una consecuencia directa en el EdgeBox, donde el LLM corre localmente sobre **llama.cpp** con modelos pequeños:

Modelo	Tamaño	Ventana de contexto
Qwen2.5 1.5B (Q4_K_M)	1.1 GB	32K tokens
Gemma 4 2B (Q4_K_M)	2.9 GB	8K tokens
Qwen3.5 2B (Q2_K_XL)	922 MB	32K tokens

 El tiempo de respuesta del LLM crecerá linealmente con el tamaño del prompt.

- Las definiciones de herramientas se envían en **cada consulta SMS** al LLM, no solo cuando se usan.
- Un modelo de 1.5B parámetros procesando ~5K tokens de tools + historial de conversación
 - consulta del usuario puede tardar entre **30 y 60 segundos** adicionales respecto al inventario actual, dependiendo del modelo y la carga del sistema.
- Si en el futuro se agregan más herramientas sin depurar las obsoletas, el prompt puede saturar la ventana de contexto de modelos pequeños como Gemma 4 (8K), dejando poco espacio para el historial de la conversación y los resultados de tools anteriores.

Recomendación: Evaluar, antes de cada nuevo despliegue, si el tiempo de respuesta total (inferencia LLM + ejecución SQL + envío SMS) se mantiene dentro de un umbral aceptable para el corresponsal en campo (≤ 60 segundos). Si se excede, considerar:

- Usar un modelo de mayor capacidad (agregando hardware especializado en inferencia).
- Aggrupar herramientas relacionadas en una sola tool con parámetro `mode` .