

Informe de Progreso 2: Configuración del Entorno de Ejecución — EdgeBox-RPI-200

Alcance: SO actual, DB, Python/dependencias, SIP-Edge, llama.cpp, config.yaml, servicios de software.

1. Sistema Operativo (Estado Actual) - Estado: COMPLETADO

El SO fue actualizado a Debian 13 (Trixie) — ver Informe 01.

Componente	Detalle
Sistema Operativo	Debian GNU/Linux 13 (trixie)
Arquitectura	aarch64 (64-bit)
Kernel	Linux 6.12.75+rpt-rpi-v8 #1 SMP PREEMPT aarch64
Dispositivo	EdgeBox-RPI-200 (Raspberry Pi Compute Module 4 Rev 1.1)
CPU	4 x ARM Cortex-A72 @ 1.5 GHz
RAM	7.6 GB total (948 MB CPU, 76 MB GPU)
Almacenamiento	32 GB eMMC (/dev/mmcblk0p2 , 14 GB usados, 14 GB libres)
Swap	2.0 GB
Hostname	SIP-Edge
Shell	bash

Comandos de verificación

```
cat /etc/os-release | grep PRETTY_NAME
# PRETTY_NAME="Debian GNU/Linux 13 (trixie)"

uname -m
# aarch64

free -h | grep Mem
# Mem: 7.6Gi total, ~650Mi used, ~6.0Gi free

df -h /
# /dev/mmcblk0p2 29G 14G 14G 49% /
```

2. Usuarios del Sistema y Permisos - Estado: COMPLETADO

La creacion de usuarios, asignacion de grupos y credenciales de acceso, estan documentadas en el Informe 01 seccion 2. Aqui se presenta el resumen del estado actual.

Usuarios

Usuario	Rol	Shell	sudo	dialout
root	Superusuario	/bin/bash	—	—
admin	Administrador del dispositivo	/bin/bash	Si	—
sipedge	Usuario de aplicacion (SIP-Edge)	/bin/bash	Si	Si
bkmngr	Backup Operator (respaldos BD)	/bin/bash	No	Si

Grupos del usuario sipedge

```
sipedge tty dialout sudo video plugdev users gpio i2c
```

Grupo	Proposito
dialout	Acceso a puertos seriales /dev/ttyACM*
sudo	Privilegios administrativos
video	Aceleracion grafica (DRM, framebuffer)
plugdev	Dispositivos USB (modem 4G)
gpio	Control de pines GPIO
i2c	Bus I2C (RTC, sensores)
tty	Acceso general a terminales
users	Grupo base de usuarios

Auto-login modo kiosco

Configurado en /etc/lightdm/lightdm.conf :

```
[Seat:*]
autologin-user=sipedge
autologin-user-timeout=0
```

Acceso SSH

```
ssh -i <clave_privada> sipedge@192.168.1.42
```

3. Red y Conectividad - Estado: COMPLETADO

La configuracion detallada del modem 4G (comandos mmcli, nmcli, scripts de red) esta en el Informe 01 seccion 3.2.
Aqui se presenta el resumen del estado actual.

Interfaces de red

Interfaz	Tipo	Estado	IP
eth0	Ethernet	UP	192.168.1.42/24
wwan0	4G LTE (Quectel EC25)	DOWN (sin plan de datos activo)	DHCP operador
wlan0	WiFi	No disponible	—
lo	Loopback	UP	127.0.0.1/8

Modem 4G LTE — Resumen

Componente	Estado
Deteccion USB (ID 2c7c:0125)	OK
Puertos: ttyUSB0 – ttyUSB3	OK
Interfaz wwan0	OK
ModemManager	Activo
SIM Tigo Colombia (732103)	Detectada
Senal LTE	89%
APN: internet.tigo.com.co	Configurado
Plan de datos activo	Pendiente

Comandos de verificacion

ip -br addr	# Interfaces de red
mmcli -m 0	# Estado del modem
mmcli -b 1	# Estado del bearer
nmcli connection show Quectel-4G	# Configuracion 4G

Scripts de gestion

Script	Funcion
/usr/local/bin/switch_network.sh status	Estado de conexiones
/usr/local/bin/switch_network.sh eth	Solo Ethernet

Script	Funcion
<code>/usr/local/bin/switch_network.sh 4g</code>	Solo 4G
<code>/usr/local/bin/switch_network.sh dual</code>	Ethernet + 4G
<code>/usr/local/bin/send_sms.sh</code>	SMS de prueba

4. Puertos Seriales — Configuracion de Software - Estado: COMPLETADO

La configuracion fisica de los puertos y permisos esta en el Informe 01 seccion 3.3. Aqui se documenta la configuracion a nivel de aplicacion.

Mapeo de puertos

Puerto	Dispositivo	Proposito
RS485	<code>/dev/ttyACM0</code>	Bascula DINI ARGEO DFWLI-2
RS232	<code>/dev/ttyACM1</code>	PC externo

Permisos

Los puertos pertenecen a `root:dialout`. El usuario `sipedge` esta en el grupo `dialout`, con acceso de lectura/escritura sin `sudo`.

```
ls -la /dev/ttyACM*
# crw-rw---- 1 root dialout 166, 0 Jun 14 09:33 /dev/ttyACM0
# crw-rw---- 1 root dialout 166, 1 Jun 14 09:33 /dev/ttyACM1
```

Configuracion en `config.yaml`

La aplicacion SIP-Edge gestiona los parametros seriales via `config.yaml`:

```
rs485:
  path: /dev/ttyACM0
  baudrate: 115200
  data_bits: 8
  parity: N
  stop_bits: 1.0

rs232:
  path: /dev/ttyACM1
  baudrate: 115200
  data_bits: 8
  parity: N
  stop_bits: 1.0
```

Los parametros pueden modificarse dinamicamente desde la API (`GET/PUT /api/config`) sin reiniciar el servicio.

5. Base de Datos — MariaDB - Estado: COMPLETADO

Instalacion

```
sudo apt install -y mariadb-server
sudo systemctl enable --now mariadb
```

Configuracion

Parametro	Valor
Version	MariaDB 11.8.6
Puerto	3306 (localhost)
Base de datos	sip_edge
Usuario de aplicacion	sip_user @ localhost
Contrasena	sip_pass
Motor	InnoDB
Socket	/run/mysqld/mysqld.sock

Creacion de la base de datos

```
CREATE DATABASE IF NOT EXISTS sip_edge;
CREATE USER IF NOT EXISTS 'sip_user'@'localhost' IDENTIFIED BY 'sip_pass';
GRANT ALL ON sip_edge.* TO 'sip_user'@'localhost';
FLUSH PRIVILEGES;
```

Tablas (creadas por SQLAlchemy al iniciar SIP-Edge)

Tabla	Contenido
users	Usuarios del sistema (admin, operadores, corresponsales)
haciendas	Haciendas (fincas)
suertes	Suertes/Lotes (vinculadas a haciendas)
weighings	Registros de pesaje
backup_logs	Registro de ejecuciones de backup

Servicio

```
sudo systemctl status mariadb
# Active: active (running)
```

6. Python y Dependencias de la Aplicacion - Estado: COMPLETADO

Runtime

Componente	Version	Ubicacion
Python	3.13.5	Sistema (<code>/usr/bin/python3</code>)
pip	25.1.1	Sistema
Entorno virtual (venv)	—	<code>/home/sipedge/sip_edge/venv</code>
Repositorio	—	<code>/home/sipedge/sip_edge</code>

Dependencias (venv)

```
annotated-types==0.7.0
anyio==4.13.0
bcrypt==4.2.1
certifi==2026.5.20
cffi==2.0.0
click==8.4.1
cryptography==44.0.0
ecdsa==0.19.2
fastapi==0.115.6
h11==0.16.0
httpcore==1.0.9
httptools==0.8.0
httpx==0.28.1
idna==3.18
passlib[bcrypt]==1.7.4
pyasn1==0.6.3
pycparser==3.0
pydantic==2.10.3
pydantic-settings==2.7.0
pydantic_core==2.27.1
PyMySQL==1.1.1
pyserial==3.5
python-dotenv==1.0.1
python-jose[cryptography]==3.3.0
PyYAML==6.0.2
rsa==4.9.1
six==1.17.0
SQLAlchemy==2.0.36
starlette==0.41.3
typing_extensions==4.15.0
uvicorn[standard]==0.34.0
websockets==14.1
```

Resumen por categoria

Categoria	Paquetes
Framework Web	FastAPI, uvicorn, starlette
ORM / BD	SQLAlchemy, PyMySQL
Autenticacion	python-jose (JWT), passlib (hash), bcrypt, cryptography
Validacion	Pydantic, pydantic-settings
Hardware	pyserial (RS232/RS485)
Utilidades	PyYAML, python-dotenv, httpx, websockets

Variables de entorno (.env)

Archivo: /home/sipedge/sip_edge/.env

```
DB_HOST=127.0.0.1
DB_PORT=3306
DB_NAME=sip_edge
DB_USER=sip_user
DB_PASSWORD=sip_pass
JWT_SECRET_KEY=sip_edge_jwt_secret_prod
ADMIN_DEFAULT_PASSWORD=admin
DEV_MODE=false
```

Variable	Proposito
DB_HOST	Host de MariaDB (localhost)
DB_PORT	Puerto de MariaDB
DB_NAME	Nombre de la base de datos
DB_USER	Usuario de BD
DB_PASSWORD	Contrasena de BD
JWT_SECRET_KEY	Clave para firmar tokens JWT
ADMIN_DEFAULT_PASSWORD	Contrasena inicial del admin
DEV_MODE	false → hardware real activo (RS485, RS232, GSM)

7. Servicio SIP-Edge (systemd) - Estado: COMPLETADO

La aplicacion SIP-Edge se ejecuta como servicio systemd con inicio automatico.

Archivo de unidad: /etc/systemd/system/sip-edge.service


```
[Unit]
Description=SIP-Edge Backend
After=network.target mariadb.service
Requires=mariadb.service

[Service]
Type=simple
User=sipedge
WorkingDirectory=/home/sipedge/sip_edge
EnvironmentFile=/home/sipedge/sip_edge/.env
ExecStart=/home/sipedge/sip_edge/venv/bin/uvicorn src.main:app --host 0.0.0.0 --port 8000
Restart=always
RestartSec=5
WatchdogSec=30

[Install]
WantedBy=multi-user.target
```

`WatchdogSec=30` agregado el 2026-06-14 para integracion con el hardware watchdog (ver Informe 01 seccion 3.4 y `[RNF-003]`). Efectivo a nivel de sistema (systemd reinicia el servicio si se cuelga). La notificacion `WATCHDOG=1` via `sd_notify()` requiere `Type=notify` y codigo adicional en la aplicacion (mejora futura).

Dependencias



Script de respaldo (`scripts/backup.py`)

Script standalone ejecutable via cron para respaldo diario de la base de datos:

- Ejecuta `mysqldump` contra `sip_edge` y comprime con gzip.
- Rota archivos manteniendo maximo 30 dias (FIFO).
- Copia a USB (`/mnt/backup_usb`) si esta montado, con verificacion CRC32.
- Registra cada ejecucion en la tabla `backup_logs` (exito o fallo).

```
# Ejecucion manual
cd /home/sipedge/sip_edge
python scripts/backup.py

# Configuracion cron (diario a las 23:55)
55 23 * * * cd /home/sipedge/sip_edge && python scripts/backup.py >> /var/log/sip_edge_backup.log 2>&1
```

Comandos de gestion

```
sudo systemctl start sip-edge      # Iniciar
sudo systemctl stop sip-edge       # Detener
sudo systemctl restart sip-edge     # Reiniciar
```

```
sudo systemctl status sip-edge      # Ver estado
sudo journalctl -u sip-edge -f      # Logs en tiempo real
```

API Endpoints (puerto 8000)

Metodo	Ruta	Funcion
GET	/	Health check basico
GET	/health	Health check
POST	/api/auth/login	Login (JWT)
GET/POST	/api/users	CRUD de usuarios (admin)
PUT	/api/users/{id}	Actualizar usuario
CRUD	/api/haciendas	Gestion de haciendas
CRUD	/api/suertes	Gestion de suertes
CRUD	/api/weighings	Captura de pesaje
POST	/api/weighings/reset	Reset de formulario
PUT	/api/setup/session	Configurar timeout de sesion
PUT	/api/setup/scale	Configurar timeout de bascula
GET/PUT	/api/config	Configuracion del sistema
POST	/api/config/test/{port}	Prueba de puerto serial/GSM
GET	/api/backup/status	Estado de respaldos (ultimos 10 registros)
POST	/api/backup/run	Disparar respaldo manual

8. llama.cpp — Motor de Inferencia LLM - Estado: COMPLETADO

Ultima actualizacion: 05 de junio de 2026 (b8763 → b9632)

Compilacion

```
git clone --depth 1 https://github.com/ggerranov/llama.cpp llama.cpp_build
cd llama.cpp_build
mkdir build && cd build
cmake .. -DCMAKE_BUILD_TYPE=Release
cmake --build . --config Release -j1 # -j1 recomendado para CM4 (4 cores, RAM limitada)
sudo cp bin/* /usr/local/bin/
```

Configuracion de hardware detectada por CMake

CMAKE_SYSTEM_PROCESSOR: aarch64
GGML_SYSTEM_ARCH: ARM
ARM flags: -mcpu=cortex-a72+crc+nodotprod+noi8mm+nosve+nosme
FMA: yes
DOTPROD: no (Cortex-A72 no soporta)
I8MM: no (Cortex-A72 no soporta)
SVE: no (Cortex-A72 no soporta)

Dependencias de compilacion

Paquete	Version	Proposito
build-essential	12.12	Compilador GCC, make, headers
cmake	3.31.6	Sistema de construccion
libssl-dev	3.5.5	SSL/TLS para llama-server

Historial de versiones

Fecha	Build	ggml	Binarios	Cambios clave
11/04/2026	b8763 (ff5ef8278)	v0.14.0	42	Instalacion inicial
14/06/2026	b9632 (1fd6dfe)	v0.15.1	49	Actualizacion actual

Cambios en la actualizacion (b8763 → b9632, +870 commits)

Categoria	Cambio
ggml	v0.14.0 → v0.15.1 — mejoras de rendimiento en backend CPU ARM
ggml-cpu	Fix en rms_norm_back para aliasing de buffers
CPU Backend	Nuevo op COL2IM_1D cuantizable para convolucion 1D
Server	PWA support, limpieza de static assets, fix reasoning budget, prompt logging
Multi-modal	Batching API para imagenes/audio (mtmd)
Jinja templates	Fix en split/replace/slice para compatibilidad con mas modelos

Binarios principales (49 en /usr/local/bin/)

Binario	Proposito
llama-server	Servidor HTTP API compatible OpenAI
llama-cli	CLI interactivo para chat
llama-bench	Benchmark de rendimiento

Binario	Proposito
llama-perplexity	Evaluacion de perplejidad
llama-quantize	Cuantizacion de modelos
llama-embedding	Generacion de embeddings
llama-gguf	Utilidad de archivos GGUF
llama-mtmd-cli	CLI multi-modal (texto + imagen + audio)
llama-simple-chat	Chat simple sin servidor

Version actual

```
llama-cli --version
# version: 1 (1fd6dfe)
# build: b1-1fd6dfe
# built with GNU 14.2.0 for Linux aarch64
```

Verificacion de inferencia

```
$ llama-cli -m /home/models/qwen2.5-1.5b-instruct-q4_k_m.gguf -p "Hello" -n 10

build      : b1-1fd6dfe
model      : qwen2.5-1.5b-instruct-q4_k_m.gguf
modalities : text

> Hello
Hello! How can I assist you today?

[ Prompt: 7.7 t/s | Generation: 3.6 t/s ]
```

Modelos descargados (/home/models/)

Modelo	Tamano	Cuantizacion	Parametros	Tipo
qwen2.5-1.5b-instruct-q4_k_m.gguf	1.1 GB	Q4_K_M	1.5B	Instruct (chat)
gemma-4-E2B-it-Q4_K_M.gguf	2.9 GB	Q4_K_M	2B	Instruct (chat)
Qwen3.5-2B-UD-Q2_K_XL.gguf	922 MB	Q2_K_XL	2B	Ultra-denso

Total ocupado: ~4.9 GB

Comando de ejemplo — servidor

```
# Modelo ligero (922 MB)
llama-server \
  -m /home/models/Qwen3.5-2B-UD-Q2_K_XL.gguf \
  -c 2048 \
```

```
--host 0.0.0.0 \
--port 8080

# Modelo balanceado (1.1 GB)
llama-server \
-m /home/models/qwen2.5-1.5b-instruct-q4_k_m.gguf \
-c 4096 \
--host 0.0.0.0 \
--port 8080
```

Consideraciones de rendimiento

Con 7.6 GB de RAM y los modelos disponibles (<= 2.9 GB), el sistema tiene entre 4.7 y 6.7 GB libres para SO, MariaDB, SIP-Edge y llama-server simultaneamente. El Cortex-A72 no tiene DOTPROD, I8MM ni SVE, pero si FMA. Rendimiento observado: ~3.6 t/s en generacion para modelos Q4_K_M de ~1.5B.

9. Archivo de Configuracion — config.yaml - Estado: COMPLETADO

Generado automaticamente por SIP-Edge en el primer arranque. Ubicacion: /home/sipedge/sip_edge/config.yaml .

Contenido actual

```
gsm:
  modem_index: 0
last_updated: '2026-06-14T15:09:07.196008+00:00'
rs232:
  baudrate: 115200
  data_bits: 8
  parity: N
  path: /dev/ttyACM1
  stop_bits: 1.0
rs485:
  baudrate: 115200
  data_bits: 8
  parity: N
  path: /dev/ttyACM0
  stop_bits: 1.0
scale:
  timeout_seconds: 3
session:
  session_timeout_minutes: 15
backup:
  usb_mount_path: /mnt/backup_usb
  local_dir: /home/bkmngr/backups
  keep_days: 30
```

Parametros


Seccion	Parametro	Valor	Descripcion
rs485	path	/dev/ttyACM0	Puerto de la bascula
rs485	baudrate	115200	Velocidad serial


Seccion	Parametro	Valor	Descripcion
rs485	parity	N	Sin paridad
rs485	data_bits	8	8 bits de datos
rs485	stop_bits	1.0	1 bit de parada
rs232	path	/dev/ttyACM1	Puerto del PC externo
rs232	baudrate	115200	Velocidad serial
gsm	modem_index	0	Indice en ModemManager
scale	timeout_seconds	3	Timeout de respuesta de bascula
session	session_timeout_minutes	15	Bloqueo por inactividad
backup	usb_mount_path	/mnt/backup_usb	Ruta de montaje del USB de respaldo
backup	local_dir	/home/bkmngr/backups	Directorio local de respaldos
backup	keep_days	30	Dias de retencion (rotacion FIFO)

10. Servicios del Sistema - Estado: COMPLETADO

Servicio	Estado	Auto-start	Funcion
mariadb.service	Active	Enabled	Base de datos MariaDB 11.8.6
sip-edge.service	Active	Enabled	Backend SIP-Edge (FastAPI + uvicorn)
ModemManager.service	Active	—	Gestion del modem 4G
NetworkManager.service	Active	—	Gestion de conexiones de red
ssh.service	Active	—	Acceso SSH remoto
cron.service	Active	—	Tareas programadas
systemd-timesyncd.service	Active	—	Sincronizacion NTP
save-hwclock.service	Active	—	Persistencia del RTC PCF8563
quectel-init.service	Active	—	Inicializacion del modem al arranque

Dependencias entre servicios





11. Resumen de Archivos Configurados

Archivo	Proposito	Informe
/boot/firmware/config.txt	Overlays RTC, I2C, UART, GPIO, WDT	Informe 01
/etc/systemd/system/save-hwclock.service	Sincronizacion RTC	Informe 01
/etc/NetworkManager/system-connections/Quectel-4G.nmconnection	Conexion 4G	Informe 01
/usr/local/bin/quectel-init.sh	Inicializacion modem	Informe 01
/etc/systemd/system/quectel-init.service	Servicio inicializacion modem	Informe 01
/usr/local/bin/switch_network.sh	Conmutacion de red	Informe 01
/usr/local/bin/send_sms.sh	Envio de SMS de prueba	Informe 01
/etc/lightdm/lightdm.conf	Auto-login modo kiosco	Informe 01
/etc/polkit-1/localauthority/50-local.d/10-modemmanager.pkla	Permisos PolicyKit modem	Informe 01
/etc/systemd/system.conf	RuntimeWatchdogSec=30	Informe 01
/etc/systemd/system.conf.d/50-watchdog-30s.conf	Override WDT 30s	Informe 01
/etc/systemd/system/sip-edge.service	Servicio SIP-Edge + WatchdogSec=30	Informe 02
/home/sipedge/sip_edge/.env	Variables de entorno SIP-Edge	Informe 02
/home/sipedge/sip_edge/config.yaml	Configuracion de hardware y sesion	Informe 02
/usr/local/bin/llama-*	Binarios llama.cpp v9632 (49 herramientas)	Informe 02

Archivo	Proposito	Informe
/home/models/*.gguf	Modelos GGUF (~4.9 GB, 3 modelos)	Informe 02

12. Conclusion

El entorno de ejecucion del EdgeBox-RPI-200 esta completamente configurado y operativo:

- **SO** Debian 13 aarch64 con kernel 6.12, 7.6 GB RAM disponibles.
- **BD** MariaDB 11.8 con base `sip_edge` y usuario de aplicacion.
- **SIP-Edge** ejecutandose como servicio systemd con auto-inicio, 15 endpoints REST en puerto 8000.
- **Watchdog** de hardware a 30s integrado con systemd (`[RNF-003]`).
- **llama.cpp** v9632 con 49 herramientas y 3 modelos GGUF (~4.9 GB).
- **Red** Ethernet activa (192.168.1.42), modem 4G configurado.

Los perifericos de hardware (RTC, RS485, RS232, modem 4G, WDT, UPS) estan documentados en el Informe 01 — Configuracion de Hardware.
